


۱_ فاز ۱:



۱.۱_ فیلتر Sobel:

هدف اصلی فیلتر سوبل تشخیص لبه‌ها در یک تصویر است. لبه‌ها تغییرات قابل توجهی در شدت یا رنگ هستند که معمولاً با مرزهای اشیاء درون تصویر مرتبط می‌شوند.

فیلتر سوبل به طور ذاتی تصویر را نرم می‌کند، زیرا عملیات همگن‌سازی به کاهش نویز و بهبود قابلیت اطمینان تشخیص لبه کمک می‌کند. این اثر نرم‌کنندگی مفید است زیرا حساسیت اپراتور

را به تغییرات کوچک در شدت پیکسل که ممکن است به لبه‌های کاذب منجر شود، کاهش می‌دهد.

در حالی که فیلتر سوبل با تأکید بر لبه‌ها، استخراج ویژگی را برای درخت‌های تصمیم و SVM تقویت می‌کند، حساسیت آن به نویز و قابلیت محدود تشخیص لبه چالش‌هایی را ایجاد می‌کند. با استفاده از تکنیک‌های پیش‌پردازش و ترکیب آن با روش‌های دیگر، می‌توان اثربخشی آن را به طور قابل توجهی افزایش داد و منجر به عملکرد بهتر در وظایف یادگیری ماشین شد.

۱.۲_فیلتر HOG:

تصویر به نواحی کوچک فضایی به نام "سل" تقسیم می‌شود. برای هر سل، یک هیستوگرام از جهت‌های گرادیان محاسبه می‌شود. این هیستوگرام توزیع جهت‌های گرادیان در آن سل را نشان می‌دهد و به طور مؤثری اطلاعات لبه و ویژگی‌های بافتی آن ناحیه را ضبط می‌کند.

هیستوگرام‌های نرمال‌شده از تمام بلوک‌ها به یک بردار ویژگی واحد، معروف به توصیفگر HOG، متصل می‌شوند. این بردار اطلاعات گرادیان را در سرتاسر تصویر خلاصه می‌کند و می‌تواند به عنوان ورودی برای الگوریتم‌های یادگیری ماشین، مانند ماشین‌های بردار پشتیبان (SVM)، برای وظایفی مانند شناسایی یا تشخیص اشیاء استفاده شود.

فیلتر HOG با ضبط اطلاعات لبه‌ای ضروری و ارائه عدم وابستگی به مقیاس، استخراج ویژگی را برای درخت‌های تصمیم و SVM تقویت می‌کند، حساسیت آن به جهت و پیچیدگی محاسباتی چالش‌هایی ایجاد می‌کند. با پیاده‌سازی تکنیک‌های پیش‌پردازش، تنظیم تطبیقی و ترکیب آن با توصیفگرهای دیگر، اثربخشی آن می‌تواند برای کاربردهای مختلف در بینایی کامپیوتری افزایش یابد.

۱.۳_فیلتر Laplacian:


هدف اصلی فیلتر لاپلاس برجسته کردن نواحی در یک تصویر است که تغییرات شدیدی در شدت وجود دارد. این ویژگی آن را برای تشخیص لبه‌ها مؤثر می‌سازد، زیرا لبه‌ها نمایانگر انتقالات قابل توجهی در مقادیر پیکسل هستند.

در حالی که فیلتر لاپلاس برای تشخیص لبه مؤثر است، همچنین به نویز حساس است. زیرا لبه‌ها را تقویت می‌کند، می‌تواند نویز موجود در تصویر را نیز تقویت کند. برای کاهش این اثر، معمولاً قبل از اعمال فیلتر لاپلاس، از یک فیلتر گاوسی برای نرم کردن تصویر استفاده می‌شود.


بطور خلاصه، فیلتر لاپلاس استخراج ویژگی را برای درخت‌های تصمیم و SVM با ارائه اطلاعات واضح از لبه‌ها تقویت می‌کند ولی حساسیت آن به نویز و عدم توانایی در ضبط اطلاعات زمینه‌ای چالش‌هایی ایجاد می‌کند. با پیاده‌سازی تکنیک‌های پیش‌پردازش، ترکیب آن با روش‌های دیگر و بهینه‌سازی پارامترها، اثربخشی آن می‌تواند برای کاربردهای مختلف در بینایی کامپیوتری و وظایف یادگیری ماشین به طور قابل توجهی افزایش یابد.

۲_ فاز ۲:

Average Image




میانگین تصاویر دیتاست:




نمونه تصاویر centered

مرکز کردن یک مجموعه داده تصویری به هم‌راستایی ویژگی‌ها و کاهش تغییرپذیری کمک می‌کند که می‌تواند عملکرد مدل را در وظایف طبقه‌بندی افزایش دهد. با این حال، مهم است که معایب احتمالی را در نظر بگیرید و استراتژی‌هایی برای حفظ زمینه مرتبط و بهبود اثربخشی کلی پیاده‌سازی کنید.



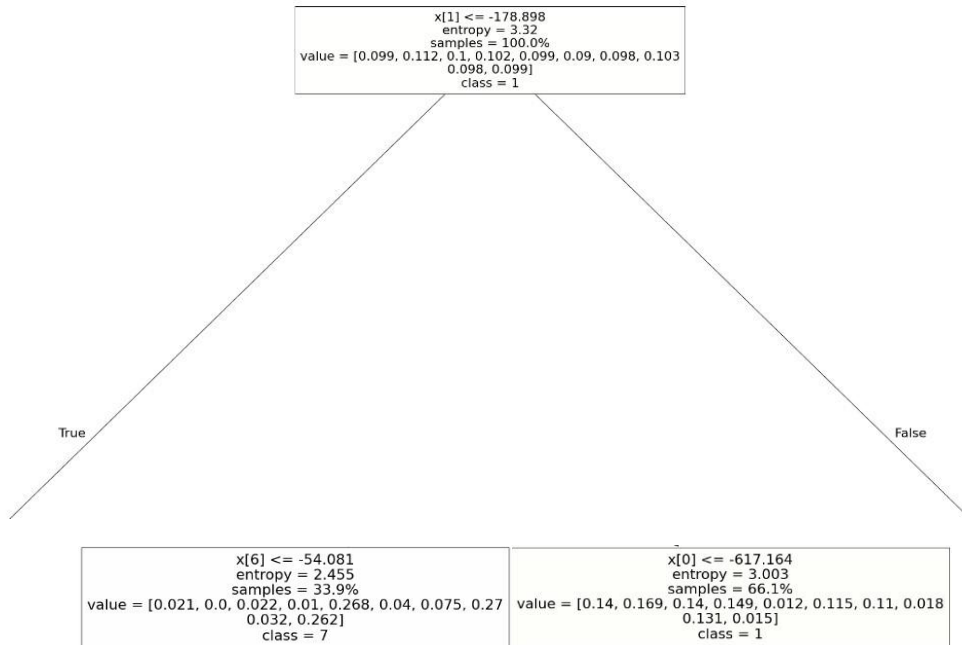
Raw data plot scree



Sobel + HOG plot scree


استفاده از نمودار اسکری با آستانه ۸۰٪ به تعیین بصری اینکه چند جزء اصلی برای ضبط بیشتر واریانس در یک مجموعه داده لازم است کمک می‌کند. این ابزار به تصمیم‌گیری‌های آگاهانه درباره کاهش ابعاد کمک کرده و اطمینان حاصل می‌کند که اطلاعات اساسی برای تحلیل‌های بیشتر حفظ شود.

۳_ فاز ۳:



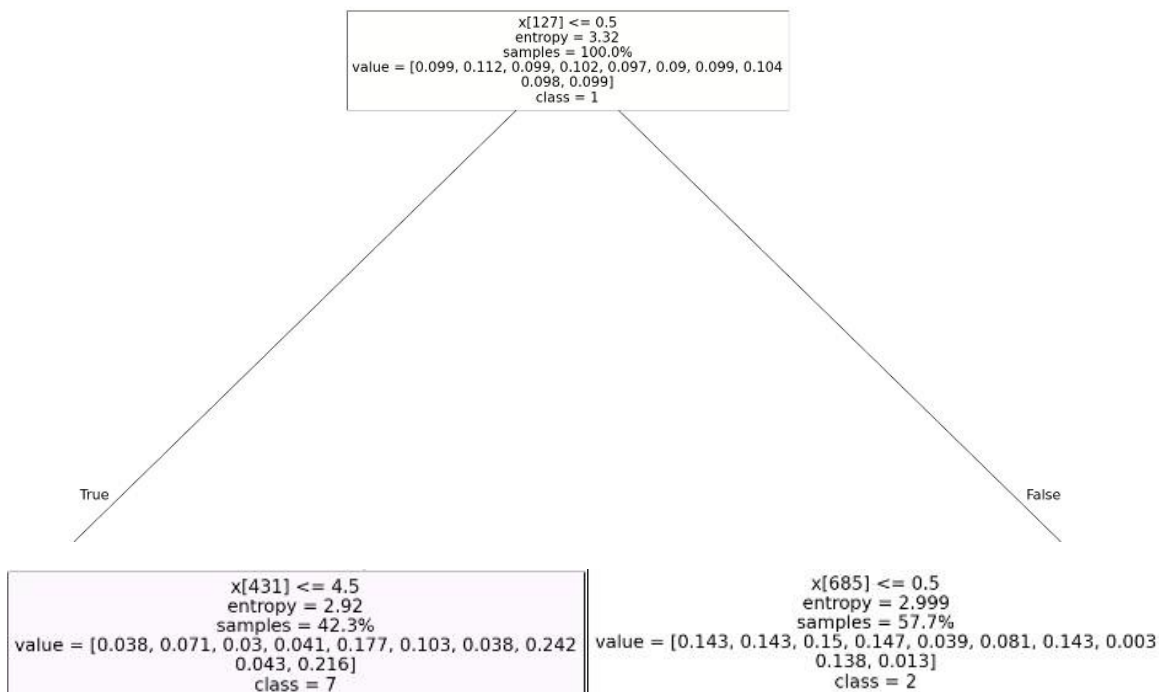
Best raw data D-tree(Accuracy: 0.86)

Best Hyperparameters: {'criterion': 'entropy', 'max_depth': 15, 'min_samples_leaf': 2, 'min_samples_split': 8}



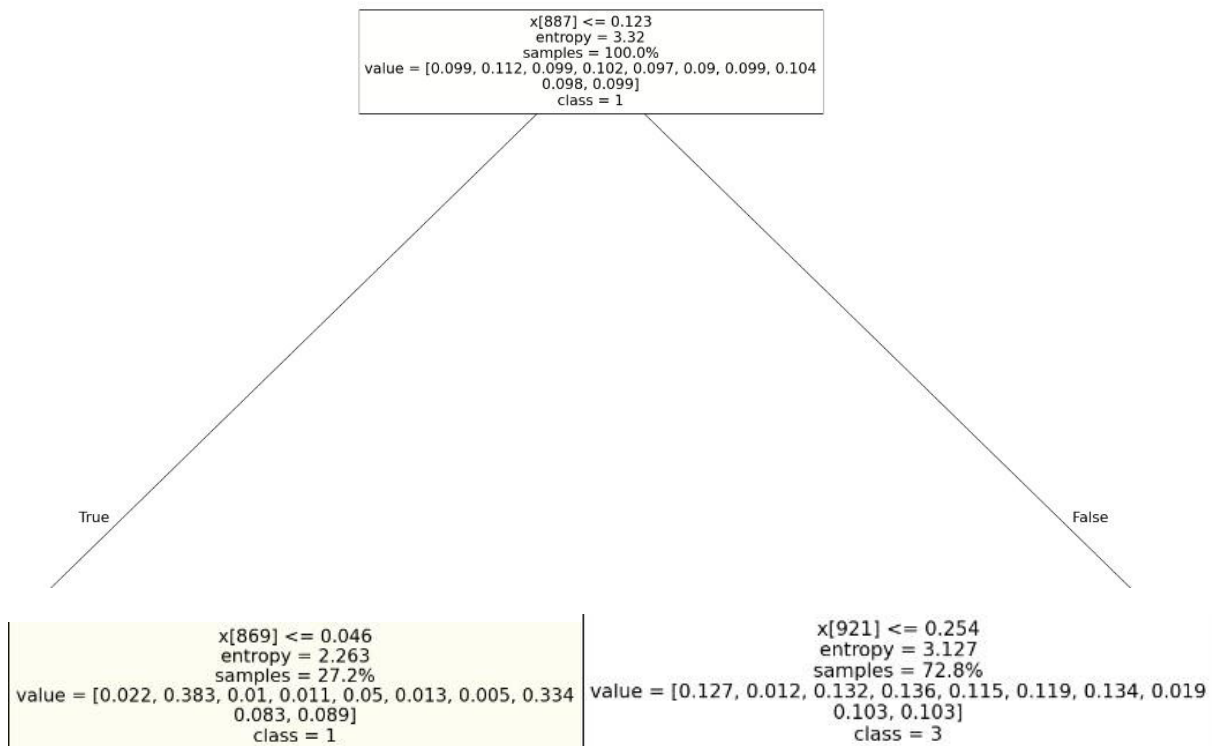
Best Sobel + HOG D-tree(Accuracy: 0.82)

Best Hyperparameters: {'criterion': 'entropy', 'max_depth': 15, 'min_samples_leaf': 5, 'min_samples_split': 5}



Best Sobel D-tree(Accuracy: 0.85)

Best Hyperparameters: {'criterion': 'entropy', 'max_depth': 20, 'min_samples_leaf': 5, 'min_samples_split': 5}



Best HOG + Laplacian D-tree(Accuracy: 0.86)

Best Hyperparameters: {'criterion': 'entropy', 'max_depth': 15, 'min_samples_leaf': 10, 'min_samples_split': 5}

در هر درخت در هر لایه بر اساس داشتن یا نداشتن threshold فیچر خود به لایه مورد نظر میرود.

همانطور که مشخص است در هر لایه که به پایین میرویم entropy کمتر و دیتا به خوبی split میشود که نشانه کیفیت درخت هاست.

K-fold cross-validation:

استفاده از $K=5$ در GridSearchCV امکان ارزیابی جامع عملکرد مدل را از طریق چرخه‌های مکرر آموزش و اعتبارسنجی فراهم می‌کند که منجر به نتایج قابل اعتمادتر در هنگام تنظیم هایپرپارامترها می‌شود.

تأثیر پارامترهای D-tree:

- این پارامترها به طور کلی کنترل‌کننده پیچیدگی و عملکرد درختان تصمیم هستند:
- تنظیم `min_samples_split` و `min_samples_leaf` کمک می‌کند تا از overfitting جلوگیری شود با کنترل اینکه تقسیمات چقدر دقیق باشند.
- تنظیم `max_depth` محدودیت‌هایی برای عمق رشد درخت ایجاد کرده و از پیچیده شدن آن جلوگیری می‌کند.
- انتخاب معیار مناسب (criterion) بر نحوه یادگیری درخت از توزیع داده‌ها تأثیر دارد.

تأثیر پارامترهای SVM:

- پارامترهای `C`، `gamma` و `kernel` تأثیرات قابل توجهی بر عملکرد SVM دارند:
- تنظیم `C` بر تعادل بین بایاس و واریانس تأثیر گذاشته و بر بیش‌براشی و کم‌براشی اثر دارد.
- تنظیم `gamma` شکل مرز تصمیم را تغییر داده و بر نحوه شناسایی الگوها توسط SVM تأثیر دارد.
- انتخاب تابع هسته مناسب تعیین‌کننده این است که SVM چقدر مؤثر می‌تواند کلاس‌ها را بر اساس ویژگی‌هایشان جدا کند.

۴_ فاز ۴:

Precision:

دقت نسبت تعداد پیش‌بینی‌های مثبت درست به همه پیش‌بینی‌های مثبت انجام‌شده توسط مدل را اندازه‌گیری می‌کند. این معیار به این سوال پاسخ می‌دهد: "از بین تمام مواردی که به‌عنوان مثبت طبقه‌بندی شده‌اند، چند مورد واقعاً مثبت بودند؟"


Recall:

نسبت تعداد پیش‌بینی‌های مثبت درست به همه موارد مثبت واقعی در مجموعه داده را اندازه‌گیری می‌کند. این معیار به این سوال پاسخ می‌دهد: "از بین تمام مثبت‌های واقعی، چند مورد را به‌درستی شناسایی کردیم؟"

F1-Score:

امتیاز F1 میانگین هارمونیک دقت و یادآوری است و یک معیار واحد ارائه می‌دهد که هر دو نگرانی را متعادل می‌کند. این امتیاز به‌ویژه در هنگام کار با مجموعه داده‌های نامتعادل مفید است.


Raw data D-tree:



Classification Report:				
	precision	recall	f1-score	support
0	0.90	0.90	0.90	1343
1	0.95	0.97	0.96	1600
2	0.84	0.86	0.85	1380
3	0.80	0.82	0.81	1433
4	0.80	0.83	0.82	1295
5	0.81	0.81	0.81	1273
6	0.90	0.92	0.91	1396
7	0.90	0.88	0.89	1503
8	0.82	0.78	0.80	1357
9	0.81	0.77	0.79	1420
accuracy			0.86	14000
macro avg	0.85	0.85	0.85	14000
weighted avg	0.86	0.86	0.86	14000

این مدل در تشخیص اعداد ۱،۶ و ۷ عملکرد خوبی داشته و اعداد ۹ و ۴ به نسبت بالایی باهم در یک کلاس قرار گرفته اند.


Sobel + HOG data D-tree:



Classification Report:				
	precision	recall	f1-score	support
0	0.87	0.89	0.88	1343
1	0.95	0.95	0.95	1600
2	0.82	0.84	0.83	1380
3	0.73	0.73	0.73	1433
4	0.79	0.82	0.80	1295
5	0.75	0.74	0.74	1273
6	0.92	0.90	0.91	1396
7	0.86	0.84	0.85	1503
8	0.74	0.73	0.73	1357
9	0.79	0.78	0.78	1420
accuracy			0.82	14000
macro avg	0.82	0.82	0.82	14000
weighted avg	0.82	0.82	0.82	14000

این مدل در تشخیص اعداد ۱،۶ و ۷ عملکرد خوبی داشته و اعداد ۵،۳ و ۸ به نسبت بالایی باهم در یک کلاس قرار گرفته اند.


Sobel D-tree:



Classification Report:				
	precision	recall	f1-score	support
0	0.85	0.89	0.87	980
1	0.95	0.95	0.95	1135
2	0.85	0.83	0.84	1032
3	0.76	0.80	0.78	1010
4	0.89	0.86	0.88	982
5	0.80	0.79	0.80	892
6	0.90	0.89	0.90	958
7	0.88	0.89	0.89	1028
8	0.79	0.77	0.78	974
9	0.86	0.85	0.85	1009
accuracy			0.85	10000
macro avg	0.85	0.85	0.85	10000
weighted avg	0.86	0.85	0.85	10000

نسبتاً عملکرد خوبی در تشخیص اعداد داشته و تنها عدد ۳ با مشکل جزئی برخوردار است.

Laplacian + HOG D-tree:




Classification Report:				
	precision	recall	f1-score	support
0	0.90	0.91	0.90	980
1	0.95	0.96	0.96	1135
2	0.82	0.84	0.83	1032
3	0.78	0.83	0.80	1010
4	0.86	0.84	0.85	982
5	0.88	0.85	0.86	892
6	0.91	0.89	0.90	958
7	0.91	0.89	0.90	1028
8	0.77	0.73	0.75	974
9	0.81	0.83	0.82	1009
accuracy			0.86	10000
macro avg	0.86	0.86	0.86	10000
weighted avg	0.86	0.86	0.86	10000

این مدل نیز از آنجایی که با فیلتر

Laplacian تقریباً عملکردی شبیه فیلتر Sobel دارد در تشخیص عدد ۳ ضعیف بوده و همچنین عدد ۸ را نیز به خوبی predict نمیکند.

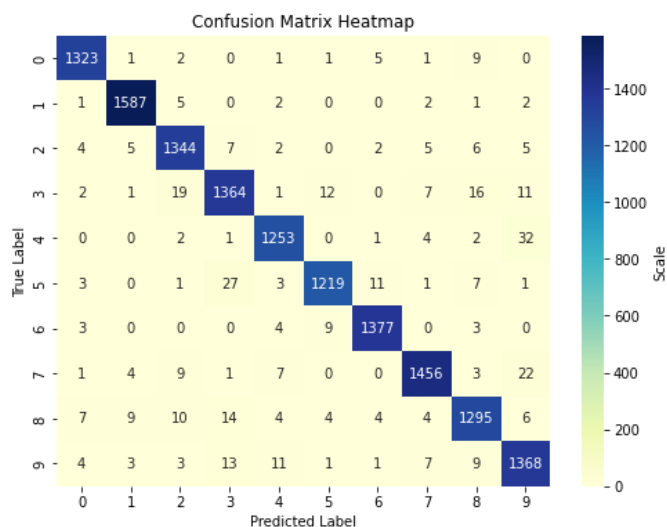
Raw data SVM:



Classification Report:				
	precision	recall	f1-score	support
0	0.99	0.99	0.99	1343
1	0.99	0.99	0.99	1600
2	0.97	0.98	0.98	1380
3	0.98	0.97	0.97	1433
4	0.98	0.98	0.98	1295
5	0.98	0.97	0.98	1273
6	0.99	0.99	0.99	1396
7	0.98	0.98	0.98	1503
8	0.98	0.97	0.98	1357
9	0.97	0.97	0.97	1420
accuracy			0.98	14000
macro avg	0.98	0.98	0.98	14000
weighted avg	0.98	0.98	0.98	14000

این مدل به خوبی prediction هارا انجام میدهد تنها مشکلات خیلی جزئی آن تشخیص ۴ با ۹ و ۷ با ۲ می باشد.

Sobel + HOG SVM:



Classification Report:				
	precision	recall	f1-score	support
0	0.98	0.99	0.98	1343
1	0.99	0.99	0.99	1600
2	0.96	0.97	0.97	1380
3	0.96	0.95	0.95	1433
4	0.97	0.97	0.97	1295
5	0.98	0.96	0.97	1273
6	0.98	0.99	0.98	1396
7	0.98	0.97	0.97	1503
8	0.96	0.95	0.96	1357
9	0.95	0.96	0.95	1420
accuracy			0.97	14000
macro avg	0.97	0.97	0.97	14000
weighted avg	0.97	0.97	0.97	14000

این مدل نیز به خوبی prediction هارا انجام میدهد و علاوه برا مشکلات مدل SVM قبل عدد ۳ را با اعداد ۸ و ۹ در برخی موارد اشتباه میگیرد.

در کل فیچر HOG + Sobel عملکرد ضعیفتری به نسبت بقیه feature vector ها داشتند.

دلایل احتمالی اینکه ترکیب ویژگی های HOG و Sobel ممکن است وکتور ویژگی مناسبی برای درخت تصمیم (D-tree) در تشخیص اعداد دست نویس نباشد، به شرح زیر است:

۱- حساسیت به اندازه و مقیاس

تغییر در اندازه و مقیاس: ویژگی های HOG به شدت به اندازه و مقیاس تصویر حساس هستند. اعداد دست نویس معمولاً در اندازه ها و مقیاس های مختلف نوشته می شوند، که می تواند منجر به کاهش دقت در شناسایی شود. اگر ویژگی ها نتوانند تغییرات اندازه را به خوبی مدیریت کنند، عملکرد مدل تحت تأثیر قرار می گیرد.

۲- پیچیدگی شکل و تنوع دست نویسی

تنوع در نوشتار: اعداد دست نویس توسط افراد مختلف با سبک های نوشتاری متفاوت نوشته می شوند. این تنوع می تواند باعث ایجاد شباهت های زیادی بین اعداد مشابه (مانند ۱ و ۷ یا ۵ و 6) شود، که ممکن است درخت تصمیم نتواند این تفاوت ها را به خوبی تشخیص دهد.

۳- ابعاد بالا و مشکل "معضل ابعاد"

افزایش ابعاد: استفاده از ویژگی های HOG و Sobel ممکن است منجر به ایجاد وکتورهای ویژگی با ابعاد بسیار بالا شود. این افزایش ابعاد می تواند منجر به مشکل "معضل

ابعاد" شود، جایی که مدل دچار بیش‌برازش (overfitting) می‌شود و نمی‌تواند به‌خوبی روی داده‌های جدید تعمیم یابد.

۴- عدم توانایی در شناسایی الگوهای پیچیده

الگوهای پیچیده: درختان تصمیم معمولاً برای شناسایی الگوهای ساده مناسب‌تر هستند. اگر ویژگی‌های استخراج‌شده نتوانند اطلاعات کافی درباره الگوهای پیچیده اعداد دست‌نویس ارائه دهند، عملکرد مدل ضعیف خواهد بود.

۵- عدم تعادل در داده‌ها

عدم تعادل کلاس‌ها: اگر داده‌های آموزشی شامل تعداد نامتعادل از نمونه‌ها برای هر عدد باشند، این موضوع می‌تواند منجر به یادگیری نادرست مدل شود. درخت تصمیم ممکن است تمایل بیشتری به طبقه‌بندی کلاس‌هایی داشته باشد که تعداد بیشتری دارند.

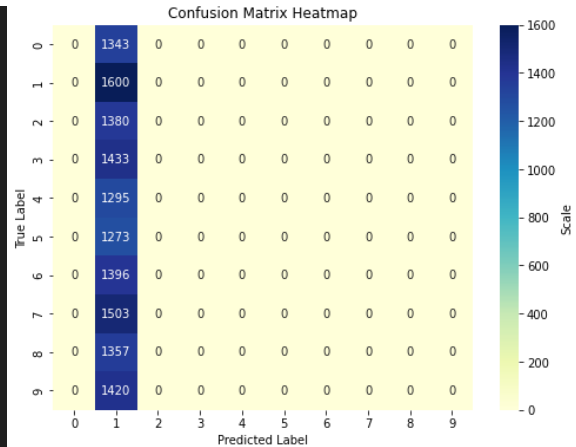
۶- نیاز به پیش‌پردازش مناسب

پیش‌پردازش ناکافی: برای استخراج ویژگی‌های مؤثر از تصاویر اعداد دست‌نویس، پیش‌پردازش مناسب (مانند نرمال‌سازی روشنایی یا حذف نویز) ضروری است. اگر این مراحل به‌درستی انجام نشود، کیفیت ویژگی‌های استخراج‌شده ممکن است تحت تأثیر قرار گیرد.

در نتیجه، ترکیب ویژگی‌های HOG و Sobel ممکن است با چالش‌هایی مواجه شود که بر توانایی درخت تصمیم در تشخیص صحیح اعداد دست‌نویس تأثیر بگذارد.

تأثیر پارامترهای خیلی بالا و پایین به روی SVM:

Classification Report:				
	precision	recall	f1-score	support
0	0.00	0.00	0.00	1343
1	0.11	1.00	0.21	1600
2	0.00	0.00	0.00	1380
3	0.00	0.00	0.00	1433
4	0.00	0.00	0.00	1295
5	0.00	0.00	0.00	1273
6	0.00	0.00	0.00	1396
7	0.00	0.00	0.00	1503
8	0.00	0.00	0.00	1357
9	0.00	0.00	0.00	1420
accuracy			0.11	14000
macro avg	0.01	0.10	0.02	14000
weighted avg	0.01	0.11	0.02	14000



ه_ فازه:

```
param_grid = {
    'max_depth': [None],
    'min_samples_split': [2],
    'min_samples_leaf': [1],
    'criterion': ['gini', 'entropy']
}
```

با تنظیم این پارامترها و اجازه دادن به درخت تا رسیدن به حداکثر عمق آنرا **overfit** میکنیم و باعث میشود به نتایج زیر برسیم.

Train Accuracy: 1.0

Test Accuracy: 0.8242142857142857

همانطور که مشاهده میشود مدل دیتای **train** را حفظ کرده است.

حال با محدود کردن عمق و استفاده از پارامترهای زیر از این اتفاق جلوگیری میکنیم.

```
param_grid = {
    'max_depth': [10],
    'min_samples_split': [5],
    'min_samples_leaf': [5],
    'criterion': ['entropy']
}
```


نتائج:

Train Accuracy: 0.8519464285714285

Test Accuracy: 0.809